


Metodi Numerici per l'Informatica

Anthony

4 apr 2023

1 Asse principale

Consideriamo dei dati in \mathbb{R}^2 . Supponiamo di voler trovare un vettore \mathbf{v} che minimizza la distanza tra i punti.



Stiamo cercando una retta, in modo analogo a abbiamo visto con la regressione lineare, ma il criterio di minimizzazione è diverso: vogliamo minimizzare la somma di tutte le norme dei complementi ortogonali.

$$\min_{\mathbf{v}} \sum_i \|\mathbf{x}_i - \text{proj}_{\mathbf{v}} \mathbf{x}_i\|_2^2 \quad \text{t.c.} \quad \|\mathbf{v}\|_2 = 1$$

Il vincolo sulla norma non è necessario, ma semplifica come risolvere il problema di ottimizzazione. Il vettore \mathbf{v} che minimizza l'errore si chiama *asse principale*. Osserviamo che possiamo traslare il problema in notazione matriciale:

$$\min_{\mathbf{v}} \sum_i \|\mathbf{x}_i - \text{proj}_{\mathbf{v}} \mathbf{x}_i\|_2^2 \quad \text{t.c.} \quad \|\mathbf{v}\|_2 = 1$$

$$= \min_{\mathbf{v}} \sum_i \left\| \mathbf{x}_i - \frac{\mathbf{x}_i^T \mathbf{v}}{\mathbf{v}^T \mathbf{v}} \mathbf{v} \right\|_2^2 \quad \text{t.c.} \quad \|\mathbf{v}\|_2 = 1$$

Dato che la norma è uguale a 1:

$$= \min_{\mathbf{v}} \sum_i \|\mathbf{x}_i - (\mathbf{x}_i^T \mathbf{v}) \mathbf{v}\|_2^2 \quad \text{t.c.} \quad \|\mathbf{v}\|_2 = 1$$

Espandiamo la norma al quadrato:

$$= \min_{\mathbf{v}} \sum_i (\mathbf{x}_i - (\mathbf{x}_i^T \mathbf{v}) \mathbf{v})^T (\mathbf{x}_i - (\mathbf{x}_i^T \mathbf{v}) \mathbf{v}) \quad \text{t.c. } \|\mathbf{v}\|_2 = 1$$

Effettuiamo i prodotti e semplici passaggi algebrici:

$$\begin{aligned} &= \min_{\mathbf{v}} \sum_i (\|\mathbf{x}_i\|_2^2 - 2(\mathbf{x}_i^T \mathbf{v})(\mathbf{x}_i^T \mathbf{v}) + (\mathbf{x}_i^T \mathbf{v})^2 \|\mathbf{v}\|_2^2) \quad \text{t.c. } \|\mathbf{v}\|_2 = 1 \\ &= \min_{\mathbf{v}} \sum_i (\|\mathbf{x}_i\|_2^2 - 2(\mathbf{x}_i^T \mathbf{v})^2 + (\mathbf{x}_i^T \mathbf{v})^2 \|\mathbf{v}\|_2^2) \quad \text{t.c. } \|\mathbf{v}\|_2 = 1 \\ &= \min_{\mathbf{v}} \sum_i (\|\mathbf{x}_i\|_2^2 - (\mathbf{x}_i^T \mathbf{v})^2) \quad \text{t.c. } \|\mathbf{v}\|_2 = 1 \end{aligned}$$

Semplifichiamo eliminando il valore che non dipende da \mathbf{v} :

$$= \min_{\mathbf{v}} - \sum_i (\mathbf{x}_i^T \mathbf{v})^2 \quad \text{t.c. } \|\mathbf{v}\|_2 = 1$$

Ora sia \mathbf{X} la matrice che contiene i vettori \mathbf{x}_i come colonne:

$$\begin{aligned} &= \min_{\mathbf{v}} -\|\mathbf{X}^T \mathbf{v}\|_2^2 \quad \text{t.c. } \|\mathbf{v}\|_2 = 1 \\ &= \max_{\mathbf{v}} \|\mathbf{X}^T \mathbf{v}\|_2^2 \quad \text{t.c. } \|\mathbf{v}\|_2 = 1 \end{aligned}$$

Che può anche essere riscritto come:

$$\max_{\mathbf{v}} \mathbf{v}^T \mathbf{X} \mathbf{X}^T \mathbf{v} \quad \text{t.c. } \|\mathbf{v}\|_2 = 1$$

Il massimizzatore che risolve il problema \mathbf{v}^* è il *componente principale* dei dati contenuti nella matrice \mathbf{X} .

2 Autovettori e autovalori

Un autovettore \mathbf{x} di una matrice quadrata \mathbf{A} è un qualsiasi vettore che soddisfa la seguente espressione:

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x} \quad \text{per qualche valore } \lambda \text{ anche complesso}$$

Il valore λ è l'*autovalore* dell'autovettore \mathbf{x} . Intuitivamente, gli autovettori di una mappa lineare \mathbf{A} sono quei vettori che, quando applichiamo \mathbf{A} , vengono solo scalati del valore λ , non vengono ruotati.

La scala di un autovettore non è importante In particolare:

$$\mathbf{A}c\mathbf{x} = c\mathbf{A}\mathbf{x} = c\lambda\mathbf{x} = \lambda c\mathbf{x}$$

Per qualunque c , otteniamo sempre lo stesso λ . Per questa ragione ci limiteremo quindi a cercare gli autovettori di norma 1.

Similarità di trasformazioni lineari Consideriamo la seguente trasformazione lineare invertibile:

$$\mathbf{A}\mathbf{T}\mathbf{x} = \lambda\mathbf{T}\mathbf{x}$$

Stiamo dicendo che $\mathbf{T}\mathbf{x}$ è un autovettore di \mathbf{A} con autovalore λ . Ora proviamo ad applicare la trasformazione lineare \mathbf{T}^{-1} a sinistra:

$$\mathbf{T}^{-1}\mathbf{A}\mathbf{T}\mathbf{x} = \lambda\mathbf{x}$$

Possiamo osservare che \mathbf{x} è un autovettore di $\underbrace{\mathbf{T}^{-1}\mathbf{A}\mathbf{T}}_{\mathbf{B}}$ con autovalore λ . Poiché le trasformazioni lineari \mathbf{A} e \mathbf{B} hanno gli stessi autovalori, diciamo che esse sono *simili* o *co-spettrali* o *iso-spettrali*.

Autovalori di matrici ortogonali Osserviamo ora una proprietà importante delle matrici ortogonali, esse hanno tutti autovalori ± 1 :

$$\begin{aligned}\mathbf{Q}\mathbf{x} &= \lambda\mathbf{x} \\ \| \mathbf{Q}\mathbf{x} \|_2^2 &= \| \lambda\mathbf{x} \|_2^2 \\ (\mathbf{Q}\mathbf{x})^T \mathbf{Q}\mathbf{x} &= |\lambda|^2 \| \mathbf{x} \|_2^2 \\ \mathbf{x}^T \mathbf{Q}^T \mathbf{Q}\mathbf{x} &= |\lambda|^2 \| \mathbf{x} \|_2^2 \\ \mathbf{x}^T \mathbf{x} &= |\lambda|^2 \| \mathbf{x} \|_2^2 \\ \| \mathbf{x} \|_2^2 &= |\lambda|^2 \| \mathbf{x} \|_2^2 \\ &= 1 = |\lambda|^2 \\ \lambda &= \pm 1\end{aligned}$$

Autovalori di matrici diagonali o triangolari superiori Gli autovalori di tali matrici sono i valori sulla diagonale principale.

Autovalori di matrici simmetriche Ricordiamo che una matrice \mathbf{A} è simmetrica se $\mathbf{A} = \mathbf{A}^T$.

Possiamo affermare che tutti gli autovalori di una matrice simmetrica sono reali. Consideriamo la coppia autovalore-autovettore (λ, \mathbf{x}) tale che $\| \mathbf{x} \|_2^2 = 1$:

$$\begin{aligned}\lambda \mathbf{x}^T \mathbf{x} &= (\lambda \mathbf{x})^T \mathbf{x} \\ &= (\mathbf{A}\mathbf{x})^T \mathbf{x} \\ &= \mathbf{x}^T \mathbf{A}^T \mathbf{x} \\ &= \mathbf{x}^T (\mathbf{A}\mathbf{x}) \\ &= \overline{(\mathbf{A}\mathbf{x})^T \mathbf{x}} \quad \text{in cui } \bar{z} \text{ è il coniugato di } z \\ &= \overline{(\lambda \mathbf{x})^T \mathbf{x}} \\ &= \bar{\lambda} \mathbf{x}^T \mathbf{x}\end{aligned}$$

Consideriamo ora due distinti autovettori $\mathbf{x}_i, \mathbf{x}_j$ con $\lambda_i \neq \lambda_j$:

$$(\mathbf{A}\mathbf{x}_i)^T \mathbf{x}_j = \mathbf{x}_i^T \mathbf{A}\mathbf{x}_j$$

$$(\lambda_i \mathbf{x}_i)^T \mathbf{x}_j = \mathbf{x}_i^T \lambda_j \mathbf{x}_j$$

Questo significa che $\mathbf{x}_i^T \mathbf{x}_j = 0$, ovvero \mathbf{x}_i e \mathbf{x}_j sono ortogonali.

Autovettori di matrici che commutano Consideriamo due matrici \mathbf{A} e \mathbf{B} . Possiamo dire che:

$$\mathbf{AB} = \mathbf{BA} \Leftrightarrow \mathbf{A} \text{ e } \mathbf{B} \text{ hanno gli stessi autovettori}$$


Possiamo anche osservare che non è detto che \mathbf{A} e \mathbf{B} abbiano gli stessi autovalori:

$$\mathbf{v}^T \mathbf{A}\mathbf{v} = \lambda \neq \mu = \mathbf{v}^T \mathbf{B}\mathbf{v}$$

Teorema di Courat L'autovettore associato all'autovalore massimo si chiama *autovettore principale*.

3 Asse principale (continua)

Torniamo al nostro problema: dobbiamo fittare una retta tra dei punti minimizzando l'errore quadratico medio perpendicolare alla retta:



Per risolvere il problema dobbiamo trovare il vettore \mathbf{v} .

$$\max_{\mathbf{v}} \mathbf{v}^T \underbrace{\mathbf{X}\mathbf{X}^T}_{\text{simmetrica}} \mathbf{v}$$

3.1 Teorema min-max

Se \mathbf{A} è una matrice simmetrica, allora il suo autovalore massimo è dato dalla seguente equazione:

$$\max_{\mathbf{v}} \frac{\mathbf{v}^T \mathbf{A}\mathbf{v}}{\|\mathbf{v}\|_2^2}$$

con \mathbf{v} il corrispettivo autovettore. Più in generale:

$$\lambda_{\min} \leq \frac{\mathbf{v}^T \mathbf{A} \mathbf{v}}{\|\mathbf{v}\|_2^2} \leq \lambda_{\max}$$

In cui il quoziente $\frac{\mathbf{v}^T \mathbf{A} \mathbf{v}}{\|\mathbf{v}\|_2^2}$ è chiamato *quoziente di Rayleigh*.

4 Teorema spettrale

L'insieme di autovalori $\{\lambda_i\}$ di una matrice \mathbf{A} è chiamata *spettro*. Possiamo scrivere l'equazione degli autovalori come:

$$\mathbf{A} \mathbf{X} = \mathbf{X} \mathbf{\Lambda}$$

Se \mathbf{A} è simmetrica, allora \mathbf{X} è una matrice ortogonale di autovettori e $\mathbf{\Lambda}$ è la matrice diagonale con autovalori reali. L'equazione appena mostrata possiamo scriverla anche nel seguente modo:

$$\mathbf{X}^T \mathbf{A} \mathbf{X} = \mathbf{\Lambda}$$

E tale equazione è chiamata la *decomposizione spettrale* di \mathbf{A} . Osserviamo che essa è molto simile al problema dell'asse principale:

$$\max_{\mathbf{x}} \mathbf{x}^T \mathbf{A} \mathbf{x} \quad \text{t.c.} \quad \|\mathbf{x}\|_2 = 1 \quad \text{asse principale}$$

Modifichiamo il problema per risolvere per tutti gli autovettori e i rispettivi autovalori:

$$\min_{\mathbf{X}} \text{tr}(\mathbf{X}^T \mathbf{A} \mathbf{X}) \quad \text{t.c.} \quad \mathbf{X}^T \mathbf{X} = \mathbf{I} \quad \text{decomposizione spettrale}$$

In questo problema stiamo minimizzando con il vincolo che \mathbf{X} sia ortogonale. Tale quesito non è convesso, ovvero non è banale trovare una soluzione globale al problema ma, per questo in problema in particolare, esistono algoritmi che permettono di risolverlo globalmente.

5 Trovare gli autovalori

Autovettore massimo (power iteration) Un algoritmo molto semplice per trovare l'autovalore più grande è quello della *normalized-iteration*, mostrato in seguito:

Algorithm 1 Normalized-Iteration

```
function NORMALIZED-ITERATION( $A$ )  
   $\vec{v} \leftarrow \text{Arbitrary}(n)$   
  for  $k \leftarrow 1, 2, 3, \dots$  do  
     $\vec{w} \leftarrow A\vec{v}$   
     $\vec{v} \leftarrow \vec{w}/\|\vec{w}\|$      $\triangleright$  la normalizzazione è atta a ridurre errori numerici  
  end for  
  return  $\vec{v}$   
end function
```

Autovalore minimo (inverse iteration) Per trovare l'autovettore minimo osserviamo che:

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x} \Rightarrow \mathbf{A}^{-1}\mathbf{x} = \frac{1}{\lambda}\mathbf{x}$$

Da ciò ne concludiamo che possiamo semplicemente applicare il power method a \mathbf{A}^{-1} . Tuttavia, esistono tecniche più efficienti che non prevedono l'inversa di \mathbf{A} , come la decomposizione LU.

5.1 Iterazione QR

Abbiamo già visto nella sezione 2. che se $\mathbf{B} = \mathbf{T}^{-1}\mathbf{A}\mathbf{T}$, allora \mathbf{A} e \mathbf{B} hanno lo stesso spettro, ovvero sono matrici simili. Per cui potremmo prima ottenere una decomposizione **QR** di \mathbf{A} :

$$\mathbf{A} = \mathbf{Q}\mathbf{R}$$

E poi sovrascrivere \mathbf{A} , mantenendo ancora gli stessi autovalori:

$$\mathbf{A} \leftarrow \mathbf{Q}^T \mathbf{A} \mathbf{Q}$$

Ora osserviamo:

$$\mathbf{Q}^T \mathbf{A} \mathbf{Q} = \mathbf{Q}^T (\mathbf{Q}\mathbf{R}) \mathbf{Q} = (\mathbf{Q}^T \mathbf{Q}) \mathbf{R} \mathbf{Q} = \mathbf{R} \mathbf{Q}$$

In altre parole, questa operazione preserva gli autovalori:

$$\mathbf{A} \leftarrow \mathbf{R} \mathbf{Q}$$

Se continuiamo ad effettuare questa operazione in modo iterativo, otteniamo l'algoritmo *QR-Iteration*:

Algorithm 2 QR-Iteration

```
function QR-ITERATION( $A \in \mathbb{R}^{n \times n}$ )  
  for  $k \leftarrow 1, 2, 3, \dots$  do  
     $Q, R \leftarrow \text{Fattorizzazione-QR}(A)$   
     $A \leftarrow RQ$   
  end for  
  return  $\text{diag}(R)$   
end function
```

Facciamo alcune osservazioni:

1. Tutte le matrici intermedie generate dall'algoritmo $\mathbf{A}_1, \mathbf{A}_2, \dots$ hanno gli stessi autovalori
2. Le iterazioni convergono, ovvero a un certo punto $\mathbf{A}_k \approx \mathbf{A}_{k-1}$
3. A convergenza, otteniamo $\mathbf{Q}_\infty^T \mathbf{A}_\infty \mathbf{Q}_\infty = \mathbf{A}_\infty$, il che implica $\mathbf{Q}_\infty \mathbf{R}_\infty = \mathbf{R}_\infty \mathbf{Q}_\infty$ e $\mathbf{A}_\infty \mathbf{Q}_\infty = \mathbf{Q}_\infty \mathbf{A}_\infty$
4. Se $\mathbf{A}_\infty \mathbf{x} = \lambda \mathbf{x}$ allora possiamo scrivere:

$$\lambda \mathbf{x} = \mathbf{A}_\infty \mathbf{x} = \mathbf{Q}_\infty \mathbf{R}_\infty \mathbf{x} = \mathbf{R}_\infty \mathbf{Q}_\infty \mathbf{x} = \pm \mathbf{R}_\infty \mathbf{x}$$

L'ultima parte dell'uguaglianza deriva dal fatto che gli autovalori di \mathbf{Q} sono ± 1 poiché essa è ortogonale. In altre parole, gli autovalori di \mathbf{A}_∞ , e quindi anche quelli di \mathbf{A} , sono uguali agli elementi sulla diagonale di \mathbf{R}_∞ a parte il segno.

6 Shifting

Data una matrice \mathbf{A} con autovalori $\{\lambda_i\}$ e autovettori $\{\mathbf{x}_i\}$:

$$(\mathbf{A} - \sigma \mathbf{I}) \mathbf{x}_i = \mathbf{A} \mathbf{x}_i - \sigma \mathbf{x}_i = \lambda_{\mathbf{x}_i} \mathbf{x}_i - \sigma \mathbf{x}_i = (\lambda_i - \sigma) \mathbf{x}_i$$

Che significa che gli autovalori di $\mathbf{A} - \sigma \mathbf{I}$ sono $\lambda_i - \sigma$, ovvero effettuando uno shift sulla matrice otteniamo lo stesso shift anche sui suoi autovalori.

Possiamo osservare che se σ è vicino all'autovalore di \mathbf{A} , allora $\mathbf{A} - \sigma \mathbf{I}$ ha un autovalore vicino allo 0. Possiamo usare questo fatto per stimare porzioni dello spettro di \mathbf{A} :

1. Effettuiamo un'ipotesi su un autovalore
2. Computiamo la matrice shiftata $\mathbf{B} = \mathbf{A} - \sigma \mathbf{I}$
3. Applichiamo l'inverse iteration su \mathbf{B} per trovare l'autovalore minimo.