


# Metodi Numerici per l'Informatica

Anthony

18 apr 2023

## 1 Principal Component

Consideriamo i seguenti dati che vivono in  $\mathbb{R}^2$ :




Vogliamo trovare il vettore  $\mathbf{v}$  tale che, per ogni data point  $\mathbf{x}_i$ , esso può essere scritto come:

$$\mathbf{x}_i = c_i \mathbf{v}$$

In altre parole, la distanza di ogni punto dalla retta misurata lungo la componente ortogonale della retta stessa deve essere più piccola possibile. Vogliamo minimizzare tale somma delle distanze.

**Un'altra prospettiva** Supponiamo di avere  $n$  punti nella matrice  $\mathbf{X} \in \mathbb{R}^{d \times n}$ :



Vogliamo approssimare i punti della matrice  $\mathbf{X}$  in una matrice con meno dimensioni  $\tilde{\mathbf{X}} \in \mathbb{R}^{k \times n}$  con  $k \ll d$ .

$$\mathbf{X}^T = \begin{pmatrix} - & \mathbf{x}_1^T & - \\ & \vdots & \\ - & \mathbf{x}_n^T & - \end{pmatrix} \approx \begin{pmatrix} - & \mathbf{x}_1^T & - \\ & \vdots & \\ - & \mathbf{x}_n^T & - \end{pmatrix} = \tilde{\mathbf{X}}^T$$


Vogliamo quindi trovare le  $k \leq d$  direzioni ortogonali con la maggior varianza. Esse spaziano il sottospazio  $k$ -dimensionale dei dati, poi vogliamo proiettare tutti i punti verso queste direzioni. Ciò induce a perdita di informazione, ma possiamo farlo con la minor perdita possibile.

## 2 PCA

In generale, applicando PCA vogliamo identificare i  $k \ll d$  assi per i quali, una volta proiettato il nostro dataset originale, minimizzano la perdita di informazione. Intuitivamente, gli assi che minimizzano la perdita di informazione sono ortogonali fra loro. Vogliamo quindi trovare la direzione  $\mathbf{w}$  tale che:

- Minimizza l'errore di proiezione/ricostruzione
- Massimizza la varianza dei dati proiettati

Le due proprietà sono dunque equivalenti:



Ovvero, trovare l'asse che minimizza l'errore di proiezione è equivalente a trovare un asse che massimizza la varianza dei dati. Possiamo pensare al PCA come a un cambio di base a meno dimensioni.

### 2.1 Notazione matriciale

Dati  $\mathbf{x}_i$  i punti e  $\mathbf{w}_i$  le assi, possiamo esprimere il problema in notazione matriciale:

$$\underbrace{\begin{pmatrix} - & \mathbf{x}_1^T & - \\ & \vdots & \\ - & \mathbf{x}_n^T & - \end{pmatrix}}_{n \times d} \underbrace{\begin{pmatrix} | & & | \\ \mathbf{w}_1 & \dots & \mathbf{w}_k \\ | & & | \end{pmatrix}}_{d \times k} = \underbrace{\begin{pmatrix} - & \mathbf{z}_1^T & - \\ & \vdots & \\ - & \mathbf{z}_n^T & - \end{pmatrix}}_{n \times k}$$

Il prodotto interno ci consente di proiettare i punti nelle  $k$  dimensioni del dataset originale. Questa proiezione può avvenire solo se le dimensioni sono ortogonali tra di loro.

Assumendo che  $\mathbf{W}^T \mathbf{W} = \mathbf{I}$ , per  $k < d$  otteniamo:

$$\mathbf{X}^T \mathbf{W} = \mathbf{Z}^T \quad \text{proiezione}$$

$$\mathbf{X} \approx \mathbf{WZ} \quad \text{ricostruzione}$$

Le due formule sono equivalenti:

$$\mathbf{X}^T \mathbf{W} = \mathbf{Z}^T \tag{1}$$

$$= \mathbf{X}^T \mathbf{W} \mathbf{W}^T = \mathbf{Z}^T \mathbf{W}^T \tag{2}$$

$$= \mathbf{X}^T = \mathbf{Z}^T \mathbf{W}^T \tag{3}$$

$$= \mathbf{X} = \mathbf{WZ} \tag{4}$$

Se  $\mathbf{W}$  non è quadrata, presenta comunque  $k$  colonne ortogonali. Una matrice  $\mathbf{W} \in \mathbb{R}^{d \times k}$  si dice *semiortogonale* se  $\mathbf{W}^T \mathbf{W} = \mathbf{I}_k$ , ovvero il prodotto con la sua trasposta è pari all'identità  $k$ -dimensionale. Poiché  $\mathbf{W}$  non è una matrice quadrata, l'operazione  $\mathbf{W} \mathbf{W}^T \approx \mathbf{I}_d$ , ovvero non è necessariamente un'identità a  $d$  dimensioni. Questo rende valida l'equazione di proiezione, tuttavia il passaggio (3) non è più del tutto valido. In virtù dell'approssimazione, possiamo dire  $\mathbf{X} \approx \mathbf{WZ}$ . Questo step è quello di ricostruzione poiché, data  $\mathbf{WZ}$ , ricostruiamo  $\mathbf{X}$  effettuando una trasformazione lineare.

### 3 Risolvere PCA

Assumendo che abbiamo dei data points  $\mathbf{X}$  centrati in zero, per un certo  $\mathbf{w}$ , la proiezione degli  $n$  punti su  $\mathbf{w}$  è  $\mathbf{X}^T \mathbf{w}$ . La varianza da massimizzare è  $\|\mathbf{X}^T \mathbf{w}\|_2^2$ :

$$(\mathbf{X}^T \mathbf{w})^T (\mathbf{X}^T \mathbf{w}) = \mathbf{w}^T \underbrace{\mathbf{X} \mathbf{X}^T}_{\mathbf{C}} \mathbf{w}$$

I cui  $\mathbf{C} \in \mathbb{R}^{d \times d}$  è la matrice simmetrica di covarianza. Vogliamo massimizzare la covarianza, quindi vogliamo risolvere il problema:

$$\max_{\mathbf{w}} \mathbf{w}^T \mathbf{C} \mathbf{w} \quad \text{t.c.} \quad \|\mathbf{w}\|_2^2 = 1$$

La soluzione è proprio  $\mathbf{w}$ , l'autovettore principale di  $\mathbf{C}$  per il principio min-max. Il suo autovalore corrispondente è  $\mathbf{w}^T \mathbf{C} \mathbf{w}$ .

### 3.1 Trovare più componenti principali

Dopo aver risolto il problema:

$$\mathbf{w}_1 = \arg \max_{\mathbf{w}} \mathbf{w}^T \mathbf{C} \mathbf{w} \quad \text{t.c.} \quad \|\mathbf{w}\|_2^2 = 1$$

Per trovare la successiva direzione ortogonale possiamo aggiungere un nuovo vincolo al problema:

$$\mathbf{w}_1 = \arg \max_{\mathbf{w}} \mathbf{w}^T \mathbf{C} \mathbf{w} \quad \text{t.c.} \quad \|\mathbf{w}\|_2^2 = 1 \text{ e } \mathbf{w}_1^T \mathbf{w} = 0$$

Ciò ci restituisce il secondo autovettore di  $\mathbf{C}$ . Iterando possiamo trovare i primi  $k$  autovettori, che corrispondono alle componenti principali di  $\mathbf{C}$ .

## 4 PCA come modello generativo

Dato un certo  $\mathbf{W}$  che soddisfa le seguenti osservazioni su  $\mathbf{X}$ :

$$\mathbf{X}^T \mathbf{W} = \mathbf{Z}^T \quad \text{proiezione}$$

$$\mathbf{X} \approx \mathbf{W} \mathbf{Z} \quad \text{ricostruzione}$$

possiamo generare nuovi dati campionando  $\mathbf{z}_{\text{new}} \in \mathbb{R}^k$  risolvendo:

$$\mathbf{x}_{\text{new}} = \mathbf{W} \mathbf{z}_{\text{new}}$$